


scriptTelios - RunPod-Kosten & Hardware-Amortisation


Executive Summary · Datenbasis: RunPod-Billing 14.03.–10.09.2026 · Hardware-Preise: hardware_optionen_scriptTelios.md (Stand Juli 2026) · Erstellt 10.09.2026

Kernaussagen

- Gesamtkosten RunPod seit Inbetriebnahme (181 Tage): 564 USD (≈ 508 €), davon 94% GPU-Laufzeit, 6% Network-Volume.
- Laufrate volle Monate (Apr-Aug): Ø 102 USD/Monat (≈ 92 €); Spanne 81–137 USD. Mai und Juli (Eval-/Entwicklungsphasen) liegen ~60 % über den Basismonaten.
- Pod läuft an 111 von 181 Tagen (61%), Ø 4.80 USD pro Betriebstag; Wochenenden nahezu ungenutzt. Der Grundkosten-Sockel (Volume) beträgt ~5 USD/Monat auch bei Stillstand.
- Amortisation bei heutiger Nutzung: 61 Monate (Case 0) bzw. 71–93 Monate (Weg A/B) – also 5–8 Jahre, jenseits der üblichen 3-Jahres-Abschreibung. Rein finanziell lohnt On-Prem erst ab ca. 3-facher Nutzung (≤ 2 Jahre).
- Der Business Case für On-Prem ist damit primär datenschutzrechtlich (AVV-/EU-Jurisdiktionsfrage entfällt, kein Auftragsverarbeiter für Inference) und kapazitiv (48–96 GB Duo-Setup), nicht die Kostenersparnis bei Ist-Nutzung.



Monat	GPU (USD)	Storage (USD)	Gesamt (USD)	Betriebstage
Mar 26	18.64	2.95	21.60	10/18
Apr 26	76.91	5.24	82.15	21/30
May 26	120.38	5.56	125.94	22/31
Jun 26	75.81	5.18	81.00	14/30
Jul 26	131.13	5.56	136.69	21/31
Aug 26	77.22	5.36	82.58	16/31
Sep 26	32.66	1.74	34.40	7/10
Summe	532.76	31.59	564.35	111/181




Amortisation Hardware (Einmalanschaffung) vs. RunPod

Annahmen: Wechselkurs 0.90 €/USD · Stromkosten On-Prem 25 €/Monat (Server 24/7, ~6 h/Tag GPU-Last, 0,35 €/kWh) · Hardwarepreise = Mittelwert der Spannen aus dem Optionenpapier inkl. Basis-System (~1.450 €) · keine Wartungs-/IT-Personalkosten, kein Restwert. Break-even = Anschaffung ÷ (RunPod-Monatskosten – Strom).

Hardware-Option	Anschaffung	Ist-Nutzung (Ø Apr-Aug)	2× Ist	3× Ist	4× Ist
RunPod-Kosten €/Monat		92 €	183 €	275 €	366 €
Case 0 - RTX PRO 4500 32 GB (= heutiger Pod)	4.050 €	61 Mon.	26 Mon.	16 Mon.	12 Mon.
Weg A - RTX A6000 48 GB (gebraucht)	4.750 €	71 Mon.	30 Mon.	19 Mon.	14 Mon.
Weg B - RTX PRO 5000 48 GB (neu)	6.200 €	93 Mon.	39 Mon.	25 Mon.	18 Mon.
Case 0 Vollausbau 96 GB (3 Karten)	9.250 €	139 Mon.	59 Mon.	37 Mon.	27 Mon.
Weg A Vollausbau 96 GB (2 Karten)	8.050 €	121 Mon.	51 Mon.	32 Mon.	24 Mon.
Weg B Vollausbau 96 GB (2 Karten)	10.900 €	164 Mon.	69 Mon.	44 Mon.	32 Mon.

Werte = Monate bis Break-even. Vollausbau-Zeilen sind nur bei entsprechend größerem Pod (48-96 GB) vergleichbar; heutiger Pod entspricht Case 0 Einstieg.



3-Jahres-Vergleich (Einstiegsvarianten)

Variante	3 Jahre bei Ist-Nutzung	3 Jahre bei 3× Ist
RunPod (heutiger Pod)	3.294 €	9.882 €
Case 0 On-Prem	4.950 €	4.950 €
Weg A On-Prem	5.650 €	5.650 €
Weg B On-Prem	7.100 €	7.100 €

Empfehlung

- Bei unveränderter Nutzung (~1 Betriebstag von 2, ~100 USD/Monat) RunPod beibehalten – die Cloud ist über 3 Jahre rund 1.000 € günstiger als die günstigste On-Prem-Variante; Stillstandstage kosten nur den Volume-Sockel.
- Kostenhebel sofort: Pod konsequent an Nicht-Nutzungstagen stoppen (bereits Praxis), Eval-Läufe bündeln; die beiden Peak-Monate zeigen, dass Entwicklungslast der größte Treiber ist.
- On-Prem entscheiden, wenn (a) der Klinikbetrieb auf ≥ 3 Therapeut:innen/Tag bzw. ~6 h GPU-Last werktäglich skaliert (dann Break-even Case 0/Weg A ≈ 16 –19 Monate) oder (b) das Datenschutzaudit die AVV-Konstellation als nicht tragfähig bewertet – dann ist die Entscheidung unabhängig vom Kostenvergleich zu treffen.
- Falls On-Prem: Weg A (A6000 gebraucht) hat den kürzesten Break-even bei 48 GB Duo-Setup; Case 0 ist die risikoärmste 1:1-Migration des heutigen Pods (Blackwell, cuda_v13, 200 W). Vorab K2 (TLS) und E3 (LUKS) aus dem Audit einplanen.